

10. Hasil Uji Coba

10. Hasil Uji Coba

Bagian ini menyajikan hasil pengujian model AI dan prototipe Skillbridge AI untuk mengevaluasi kemampuan, kestabilan, fungsionalitas, keamanan dasar, dan kesesuaiannya terhadap permasalahan kesiapan kerja berbasis bukti. Pengujian dilaksanakan pada 24 Agustus 2026 terhadap deployment produksi <https://skillbridge-6ndn.vercel.app> dengan data sintetis. Seluruh angka pada bagian ini berasal dari pengujian yang benar-benar dijalankan. Hasil belum boleh ditafsirkan sebagai bukti bahwa model setara dengan penilai ahli karena baseline dua penilai manusia belum selesai.

10.1 Metode Pengujian

Pengujian dibagi menjadi empat kelompok:

1. **Pengujian struktural**, untuk memeriksa integritas dataset, konsistensi rubrik, perhitungan skor berbobot, validasi tipe file, URL GitHub, dan pemetaan pesan autentikasi.
2. **Pengujian model AI**, untuk mengukur keberhasilan respons terstruktur, kecukupan bukti, kestabilan tiga pengulangan, dan latensi end-to-end.
3. **Pengujian prototipe**, untuk memeriksa autentikasi, navigasi, tiga jenis bukti, persistence Supabase, riwayat, rekomendasi, wawancara, isolasi data, dan penghapusan.
4. **Pengujian antarmuka**, untuk memeriksa responsivitas desktop/mobile, struktur semantik dasar, label form, state autentikasi, dan overflow horizontal.

Model evaluator menggunakan Groq `openai/gpt-oss-20b` dengan temperature 0 dan strict JSON schema. Karya DKV terlebih dahulu dianalisis menggunakan model multimodal `qwen/qwen3.6-27b`, kemudian observasi visual dinilai oleh evaluator teks. Rubrik yang digunakan adalah versi 1.0. Setiap

bidang memiliki empat kriteria dengan skor anchor 0, 25, 50, 75, dan 100. Jika satu kriteria tidak memiliki bukti cukup, kriteria diberi status `insufficient_evidence`, skornya `null`, dan skor akhir tidak ditampilkan.

Skor akhir dihitung aplikasi dengan persamaan:

$$\text{Skor akhir} = \sum (\text{skor kriteria} \times \text{bobot kriteria})$$

Model tidak diperbolehkan menentukan skor akhir. Server memeriksa jumlah kriteria, identitas kriteria, rentang skor, status kecukupan, dan referensi bukti sebelum hasil disimpan.

10.2 Data dan Skenario Pengujian

Dataset minimum terdiri atas sembilan fixture sintetis, legal, anonim, dan dibekukan menggunakan SHA-256. Distribusinya sebagai berikut:

Bidang	Target peran	Sampel	Bentuk bukti
Informatika	Junior Web Developer	3	Kode, struktur proyek, README, dan riwayat commit
DKV	Junior Graphic Designer	3	PNG hasil karya dan deskripsi brief/proses
Bisnis/Pemasaran	Junior Digital Marketer	3	PDF laporan dengan text layer dan data sintetis
Total		9	Tiga struktur bukti berbeda

Manifest memuat 21 artefak utama. Verifikasi ulang menghasilkan 21 dari 21 hash cocok. Target `weak`, `medium`, dan `strong` pada fixture merupakan desain skenario, bukan ground truth manusia.

Skenario model produksi terdiri atas 13 assessment live:

- tiga pengulangan satu repositori Informatika publik;
- DKV lemah satu run, DKV sedang tiga run, dan DKV kuat satu run;
- Marketing lemah satu run, Marketing sedang tiga run, dan Marketing kuat satu run.

Skenario prototipe mencakup autentikasi anonim dan login, direct route protection, pilihan tiga bidang, validasi consent, file palsu, file lebih dari 4 MB, cross-account access, RLS, private Storage, interview, riwayat, dan delete cascade.

10.3 Metrik Evaluasi

Aspek	Metrik
Integritas data	Jumlah hash cocok terhadap manifest
Kepatuhan output	HTTP sukses, empat kriteria, skor anchor valid, referensi bukti tersedia
Kecukupan bukti	Jumlah hasil <code>sufficient</code> dan <code>insufficient_evidence</code>
Stabilitas	Konsistensi status dan skor pada tiga input identik
Efisiensi	Minimum, median, persentil ke-95, maksimum latensi end-to-end
Fungsionalitas	Jumlah skenario prototipe lulus/gagal
Keamanan dasar	HTTP authorization, cross-account isolation, RLS, bucket privacy, residual data
Responsivitas	Overflow horizontal pada desktop, 390 px, dan 320 px
Relevansi sumber	Status HTTP 12 URL katalog belajar

Metrik akurasi, MAE, precision, recall, F1, dan agreement terhadap manusia belum dihitung karena `HUMAN_RATINGS.csv` masih memiliki 0 dari 36 baseline kriteria yang selesai.

10.4 Hasil Pengujian Struktural

Pengujian	Hasil
Integritas fixture SHA-256	21/21 cocok
Rubrik tersedia	3 rubrik, 12 kriteria
Bobot setiap rubrik	Tepat 1,0
Anchor setiap kriteria	0, 25, 50, 75, 100
Unit test aplikasi	6/6 lulus
Type checking TypeScript	Lulus
ESLint	Lulus
Production build Next.js	Lulus
Audit dependency	0 kerentanan high/critical

Hasil tersebut menunjukkan bahwa struktur rubrik, perhitungan skor, parser URL GitHub, magic-byte file, pemilihan tipe bukti, dan pemetaan error autentikasi telah memiliki pemeriksaan otomatis. Hasil ini belum mengukur ketepatan penilaian AI terhadap manusia.

10.5 Hasil Pengujian Model AI

10.5.1 Keberhasilan dan Latensi

Pada batch awal, 11 dari 13 assessment menghasilkan HTTP 200 atau tingkat keberhasilan 84,62%. Dua kegagalan terjadi pada sampel Marketing sedang karena model menghasilkan array tujuh elemen, sementara schema mewajibkan tepat empat object kriteria. Sistem menolak output tersebut dan tidak menyimpan assessment selesai.

Setelah ditambahkan satu retry terkontrol untuk pelanggaran schema dan pesan error generik, sampel Marketing sedang diuji ulang tiga kali. Dua run berhasil dan satu run gagal aman dengan HTTP 502. Dengan demikian, provider masih menunjukkan variasi schema pada sampel tersebut; retry mengurangi tetapi belum menghilangkan kegagalan.

Statistik latensi 11 assessment HTTP 200 pada batch awal:

Metrik	Latensi
Minimum	3,359 detik
Median	18,124 detik
Persentil ke-95	34,712 detik
Maksimum	34,712 detik
Selesai di bawah 60 detik	11/11

Keberhasilan batch awal	
HTTP 200	 84,62% (11)
HTTP 502	 15,38% (2)

10.5.2 Kecukupan Bukti

Dari 11 hasil HTTP 200 pada batch awal, tiga assessment berstatus `sufficient` dan delapan berstatus `insufficient_evidence`. Distribusi ini menunjukkan model cenderung konservatif pada bukti minimal, tetapi belum dapat disebut benar atau salah tanpa baseline manusia.

Sampel	Hasil utama
Informatika octocat/Hello-World, 3 run	Ketiga run konsisten <code>insufficient_evidence</code> ; riwayat kontribusi diberi skor 25, kriteria lain tidak cukup
DKV lemah	Konsistensi visual skor 0; proses dan problem solving tidak cukup
DKV sedang, 3 run	Tidak stabil: dua run <code>insufficient_evidence</code> , satu run <code>sufficient</code> dengan skor akhir 58
DKV kuat	<code>Sufficient</code> ; seluruh kriteria 75; skor akhir 75
Marketing lemah	Seluruh kriteria <code>insufficient_evidence</code>
Marketing sedang, batch awal	Dua schema failure; satu hasil <code>insufficient_evidence</code>
Marketing kuat	<code>Sufficient</code> ; seluruh kriteria 75; skor akhir 75

Temuan DKV sedang merupakan limitation utama. Walaupun temperature 0, status kecukupan berubah pada input identik. Ini membuktikan bahwa temperature rendah tidak menjamin determinisme provider.

10.5.3 Validitas Output dan Referensi Bukti

Seluruh hasil HTTP 200 memuat empat kriteria yang sesuai bidang. Skor non-null hanya menggunakan anchor yang diizinkan. Hasil sufficient memiliki referensi bukti yang berasal dari allowlist, seperti REPOSITORY, FILES, COMMITS, README, [IMAGE:1], [DESCRIPTION:1], atau [PAGE:1]. Dua output schema-invalid ditolak sebelum persistence, sehingga sistem gagal aman.

10.5.4 Perbandingan dengan Manusia

Simulasi blind review telah dilakukan oleh dua subagent AI yang diberi identitas AI_SIM_R1 dan AI_SIM_R2. Keduanya menilai 36 kriteria secara independen tanpa membaca fixtures/expected.json, hasil model produksi, atau penilaian satu sama lain. Kedua penilai sepakat pada status kecukupan seluruh 36 kriteria; tiga perbedaan skor sebesar 25 poin telah melalui adjudikasi AI. Hasil lengkap berada di HUMAN_RATINGS.xlsx dan diberi provenance AI-simulated.

Simulasi tersebut menguji kesiapan instrumen, keterbacaan rubrik, dan proses adjudikasi, tetapi **bukan baseline manusia**. Karena dua HR manusia belum melakukan blind review, laporan ini tetap tidak menyatakan akurasi model, kesetaraan dengan ahli, MAE, F1, atau agreement manusia–model.

10.6 Hasil Pengujian Prototipe

Deployment produksi diuji pada <https://skillbridge-6ndn.vercel.app>.

Skenario	Hasil
Health endpoint dan koneksi Supabase	HTTP 200, <code>checks.supabase=true</code>
API assessment tanpa token	HTTP 401
API assessment dengan token acak	HTTP 401
Login email/password	Berhasil, redirect ke <code>/assess</code>
Navbar pengguna anonim	Hanya Daftar dan Masuk
Direct <code>/assess</code> tanpa login	Redirect ke <code>/auth?next=/assess</code>
Navbar pengguna login	Penilaian, Riwayat, Keluar
Consent tidak dicentang	HTTP 400, model tidak dipanggil
File dengan ekstensi PDF tetapi magic bytes SVG	HTTP 400
File PNG 4 MB + 1 byte	HTTP 400, tanpa residual row
Akun pemilik membaca evidence	13 row uji terlihat
Akun kedua membaca evidence pemilik	0 row
Akun kedua membuka assessment ID pemilik	Array kosong, data tidak bocor
Akun kedua memulai interview assessment pemilik	HTTP 404
Bucket evidence	Private, batas 4.194.304 byte
Interview assessment sendiri	HTTP 200, 2,361 detik
Delete assessment upload	HTTP 204
Residual setelah delete	0 assessment, 0 evidence, 0 score, 0 object Storage
Cache respons privat setelah perbaikan	<code>Cache-Control: private, no-store</code>

Pengujian memperlihatkan bahwa authentication, ownership check, RLS read isolation, private Storage, dan delete cascade bekerja pada data sintetis. Namun operasi database server menggunakan service-role client sehingga RLS bukan satu-satunya boundary; filter ownership aplikasi tetap kritis.

10.6.1 Uji Langsung Tiga Bidang pada Deployment Produksi

Pada 28 Agustus 2026, alur penilaian dijalankan langsung melalui browser pada deployment produksi memakai akun ryandraa27@gmail.com. Setiap bidang dipilih satu per satu, bukti diisikan pada form, persetujuan pemrosesan AI dicentang, lalu form dikirim dan ditunggu sampai halaman hasil tampil. Tiga hasil kemudian diperiksa pada halaman riwayat akun yang sama.

Bidang	Bukti yang dikirim	Hasil live	Re
Informatika	Repositori publik octocat/Hello-World	insufficient_evidence	571d785dc97141630e
DKV	fixtures/design/strong.png dan deskripsi proses	70/100	47151875c9a1e81b40
Bisnis/Pemasaran	fixtures/marketing/strong.pdf	81/100	fdd7c5c329817e082f

Hasil Informatika tidak diberi skor akhir karena sebagian bukti repositori tidak cukup. Perilaku ini sesuai kontrak sistem: bukti yang tidak tersedia tidak diubah menjadi skor nol. DKV menghasilkan 70/100 berdasarkan gambar dan deskripsi proses. Bisnis/Pemasaran menghasilkan 81/100 berdasarkan laporan kampanye dengan text layer. Ketiga assessment tersimpan berurutan pada riwayat akun.

SB Skillbridge AI

PenilaianRiwayatKeluar

Lewati ke konten

PENILAIAN BARU

Bawa satu bukti.

GitHub untuk Informatika, gambar karya untuk DKV, atau PDF laporan untuk Bisnis/Pemasaran.

Bidang dan target peran

Informatika – Junior Web Developer

Rubrik versi 1.0 dipilih dari target ini.

URL repositori GitHub publik

https://github.com/pemilik/repositori

Kode tidak dijalankan, Sistem membaca metadata, tree, README, dan 10 commit terbaru.

☐ Persetujuan pemrosesan AI

Bukti dikirim ke Grog untuk dinilai. Nama dan email tidak dibutuhkan. Saya memahami batas penilaian dan dapat menghapus hasil melalui akun.

Kirim dan nilai bukti!

SEBELUM MENGRIM

Repositori kode

Kualitas kode, struktur proyek, dokumentasi README, dan pola kontribusi.

Hasil dan file tersimpan privat di Supabase. File hanya diproses server dan dapat dihapus bersama hasil.

Prototipe evaluasi indikator berbasis bukti. Bukan verifikasi kompetensi atau jaminan kerja.

Gambar 3. Form uji langsung bidang Informatika sebelum submit.

SB

Skillbridge AI

Penilaian

Riwayat

Keluar

RUBRIK 1.0 - JUNIOR WEB DEVELOPER

Bukti belum cukup

Penilaian indikatif berdasarkan bukti yang dikirim. Bukan verifikasi identitas, kepemilikan karya, atau jaminan diterima kerja.

KRITERIA 1

Kualitas kode

Bukti kurang

Confidence: low

Tidak ada file kode relevan.

FILES

KRITERIA 2

Riwayat kontribusi

50/100

Confidence: medium

Minimal tiga commit dengan pesan dasar.

COMMENTS

KRITERIA 3

Dokumentasi

Bukti kurang

Confidence: low

README tidak lengkap.

README

KRITERIA 4

Struktur proyek

Bukti kurang

Confidence: low

Tree repositori tidak tersedia.

FILES

KEKUATAN

Ada tiga commit

Ada README

GAP UTAMA

Tidak ada file kode

Tidak ada struktur proyek

Dokumentasi README minimal

BATAS PENILAIAN

Data tidak dapat dipercaya

Tidak ada file kode relevan

LANGKAH BERIKUTNYA

Materi dari katalog terkurasi.

Git commit guidance

Dipilih untuk gap riwayat kontribusi.

Mulai wawancara

Nilai bukti baru

Hapus hasil

Prototipe evaluasi indikatif berbasis bukti. Bukan verifikasi kompetensi atau jaminan kerja.

Gambar 4. Hasil live Informatika dengan status bukti belum cukup.

SB Skillbridge AI

PenilaianRiwayatKeluar

PENILAIAN BARU

Bawa satu bukti.

GitHub untuk Informatika, gambar karya untuk DKV, atau PDF laporan untuk Bisnis/Pemasaran.

Bidang dan target peran

DKV – Junior Graphic Designer

Rubrik versi 1.0 dipilih dari target ini.

Gambar hasil karya

Choose File strong.png

Unggah satu PNG/JPEG hasil karya. Jelaskan brief, audiens, keputusan, dan minimal dua tahap proses atau iterasi. Maksimal 4 MB.

strong.png · 94 KB

Deskripsi proyek dan proses

Dashboard kesiapan kerja untuk mahasiswa tingkat akhir yang perlu memahami skor dan gap dengan cepat. Iterasi pertama memakal kartu setara, feedback menunjukkan skor dan tindakan sulit ditemukan. Iterasi kedua membesarkan skor, membatasi warna status, memperkuat hierarki, dan menguji layout desktop serta mobile. Constraint utama adalah aksesibilitas kontras dan kepadatan informasi.

Minimal 80 karakter. Sertakan brief/masalah, target audiens, keputusan visual, dan minimal dua tahap atau iterasi.

☒ Persetujuan pemrosesan AI

Bukti dikirim ke Groq untuk dinilai. Nama dan email tidak dibutuhkan. Saya memahami batas penilaian dan dapat menghapus hasil melalui akun.

Kirim dan nilai bukti

SEBELUM MENGRIM

Karya visual dan proses

Konsistensi visual, proses/iterasi, narasi portofolio, dan pemecahan masalah desain.

Hasil dan file tersimpan privat di Supabase. File hanya diproses server dan dapat dihapus bersama hasil.

Gambar 5. Form uji langsung DKV sebelum submit.

SB

Skillbridge AI

Penilaian

Riwayat

Keluar

RUBRIK 1.0 - JUNIOR GRAPHIC DESIGNER

70₁₀₀

Penilaian indikatif berdasarkan bukti yang dikirim. Bukan verifikasi identitas, kepemilikan karya, atau jaminan diterima kerja.

KRITERIA 1 Narasi desain 50/100 Confidence: medium	Deskripsi mencakup masalah dan target audiens, namun alasan keputusan desain kurang terhubung. [DESCRIPTION:1]
KRITERIA 2 Pemecahan masalah 75/100 Confidence: high	Brief dan constraint dijelaskan, serta solusi visual terintegrasi dengan kebutuhan utama. [DESCRIPTION:1]
KRITERIA 3 Proses dan iterasi 75/100 Confidence: medium	Deskripsi menyebutkan dua tahap iterasi dengan feedback dan revisi yang jelas. [DESCRIPTION:1]
KRITERIA 4 Konsistensi visual 75/100 Confidence: high	Gambar menunjukkan konsistensi tipografi, warna, dan komposisi yang kohesif dan bertujuan. [IMAGE:1]

KEKUATAN
 Konsistensi visual yang baik
 Iterasi proses dengan feedback
 Target audiens jelas
 Integrasi constraint dalam solusi

GAP UTAMA
 Kurang contoh variasi layout lintas format
 Tidak ada dokumentasi proses eksplorasi awal

BATAS PENILAIAN
 Data tidak terverifikasi
 Deskripsi tidak lengkap tentang trade-off desain

LANGKAH BERIKUTNYA

Materi dari katalog terkurasi.

Nielsen Norman Group: UX portfolios
 Dipilih untuk gap narasi desain.

Mulai wawancara

Nilai bukti baru

Hapus hasil

Prototipe evaluasi indikatif berbasis bukti. Bukan verifikasi kompetensi atau jaminan kerja.

Gambar 6. Hasil live DKV sebesar 70/100.

SB Skillbridge AI

PenilaianRiwayatKeluar

RUBRIK 1.0 · JUNIOR DIGITAL MARKETER

81/100

Penilaian indikatif berdasarkan bukti yang dikirim. Bukan verifikasi identitas, kepemilikan karya, atau jaminan diterima kerja.

KRITERIA 1

Penggunaan data

75/100

Confidence: medium

Menampilkan metrik relevan (CTR, CVR, CPA, ROAS) dengan definisi, sumber, dan perhitungan. Data memandu keputusan, namun belum dapat diaudit sepenuhnya.

PAGE: 1/1

KRITERIA 2

Hasil terukur

75/100

Confidence: medium

Menyediakan KPI baseline, periode, hasil aktual, dan kaitan dengan aktivitas kampanye. Atribusi terbatas pada last-click, sehingga tidak sepenuhnya transparan.

PAGE: 1/1

KRITERIA 3

Metodologi kampanye

100/100

Confidence: high

Berisi hipotesis, funnel eksplisit, target audiens mahasiswa tingkat akhir, kanal, dan evaluasi baseline serta hasil. Semua komponen dasar dan saling terhubung terpenuhi.

PAGE: 1/1

KRITERIA 4

Kualitas laporan

75/100

Confidence: medium

Laporan terstruktur dengan metode, data, kesimpulan, dan tindak lanjut. Data terhubung ke aksi, namun belum auditabilitas penuh.

PAGE: 1/1

KEKUATAN

Hipotesis dan funnel eksplisit

Baseline metrics dan perhitungan transparan

Keputusan berbasis data

Laporan terstruktur dengan aksi

GAP UTAMA

Atribusi terbatas pada last-click

Tidak ada kontrol musim penerimaan mahasiswa

Data tidak dapat diaudit sepenuhnya

Tidak ada data real bisnis

BATAS PENILAIAN

Data sintetis, bukan performa nyata

Tidak ada kontrol musiman

Atribusi terbatas

Tidak ada evaluasi jangka panjang

LANGKAH BERIKUTNYA

Materi dari katalog terkurasi.


Mulai wawancara

Nilai bukti baru

Hapus hasil

Prototipe evaluasi indikatif berbasis bukti. Bukan verifikasi kompetensi atau jaminan kerja.

Gambar 8. Hasil live Bisnis/Pemasaran sebesar 81/100.



Gambar 9. Riwayat akun menampilkan tiga assessment baru secara berurutan.

Rekaman browser memuat 32 frame dan tersimpan di `/Users/rian/.config/browser-harness/agent-workspace/recordings/skillbridge-live-three-fields`. Screenshot membuktikan alur form, submit, hasil, dan persistence benar-benar dijalankan. Screenshot tidak membuktikan ketepatan skor terhadap HR manusia.

10.7 Hasil Pengujian Antarmuka

Pengujian browser dilakukan memakai Chromium pada desktop dan mobile.

Pemeriksaan	Hasil
Landing desktop	Satu main, heading benar, tiga kartu bidang, tanpa overflow
Bahasa dokumen	lang="id"
Navbar anonim	Daftar, Masuk
Auth gate	Form assessment tidak tampil sebelum login
Form Informatika	URL GitHub, tanpa file input
Form DKV	PNG/JPEG, deskripsi proses, tanpa URL GitHub
Form Marketing	PDF, 4 MB, 15 halaman
Mobile 390 px	Tidak ada horizontal overflow
Mobile 320 px sebelum perbaikan	Overflow sekitar 10 px pada navbar login
Mobile 320 px setelah perbaikan	Lulus; lebar viewport dan scroll width sama-sama 320 px
History	Hasil tiga bidang tampil berurutan, tanpa overflow desktop
Result	Empat kriteria, batas klaim, interview, reassess, delete

Rekaman interaksi production terbaru tersimpan pada:

```
/Users/rian/.config/browser-harness/agent-workspace/recordings/skillbridge-live-three-fields
```

10.8 Hasil Pengujian Rekomendasi

Katalog saat ini merupakan mapping deterministik, bukan RAG berbasis embedding. Setiap satu dari 12 kriteria memiliki satu sumber belajar terpetakan. Pemeriksaan HTTP awal menemukan 11 URL aktif dan satu URL 404. URL tersebut diganti dengan sumber Nielsen Norman Group yang aktif. Setelah perbaikan, seluruh 12 kriteria memiliki URL katalog yang terpetakan, tetapi relevansi pedagogis belum dinilai oleh dua manusia. Target relevansi 80% masih merupakan acceptance criterion, bukan hasil.

10.9 Kelebihan Solusi

1. Sistem menerima tiga bentuk bukti berbeda: repositori GitHub, karya visual, dan laporan PDF.
2. Penilaian menggunakan rubrik khusus bidang dan bukti tidak cukup tidak dipaksa menjadi skor nol.
3. Skor akhir dihitung server, bukan dipercaya dari satu angka keluaran model.
4. Strict schema dan validasi referensi mencegah banyak keluaran tidak konsisten tersimpan.
5. Output schema-invalid gagal aman dan tidak menjadi assessment selesai.
6. Data pengguna terisolasi melalui authentication, ownership filter, RLS, dan private Storage.
7. File diperiksa dari magic bytes, bukan hanya ekstensi atau MIME browser.
8. Kode GitHub tidak dijalankan sehingga risiko eksekusi kode pengguna berkurang.
9. Penghapusan assessment menghapus row turunan dan object Storage pada skenario normal.
10. UI adaptif mengikuti jenis bukti tiap bidang dan bekerja pada desktop serta mobile utama.

10.10 Keterbatasan

1. Dataset hanya sembilan fixture sintetis dan belum mewakili populasi mahasiswa Indonesia.
2. Baseline dua penilai manusia belum selesai, sehingga akurasi dan agreement belum dapat dihitung.
3. Run resmi sembilan sampel $\times$ tiga pengulangan belum lengkap. Pengujian model dan tiga uji live terbaru masih merupakan batch produksi terbatas.
4. DKV sedang menunjukkan perubahan status kecukupan pada input identik.
5. Marketing sedang masih mengalami satu kegagalan schema setelah retry.

6. Token usage dan biaya provider belum dicatat oleh aplikasi.
7. Informatika belum diuji memakai tiga repository fixture weak/medium/strong karena fixture lokal belum dipublikasikan sebagai GitHub repository.
8. Parser PDF hanya menerima text layer; OCR untuk dokumen scan belum tersedia.
9. Sistem menilai isi bukti tetapi tidak memverifikasi identitas atau kepemilikan karya.
10. Kode repository tidak dijalankan; perilaku runtime tidak dinilai.
11. Rekomendasi masih katalog statis, belum retrieval semantik atau RAG berbasis embedding.
12. Relevansi rekomendasi belum dinilai manusia.
13. Wawancara belum disimpan lintas refresh; sesi masih berada dalam state browser.
14. Rate limit dan idempotency assessment belum tersedia.
15. Delete normal telah diuji, tetapi partial failure antara Storage dan database belum diuji dengan fault injection.
16. Pengujian Firefox, WebKit, automated WCAG scanner, contrast ratio, dan keyboard penuh belum dilakukan.

10.11 Kesimpulan Pengujian

Pengujian menunjukkan bahwa prototipe Skillbridge AI telah mampu menjalankan alur utama secara end-to-end pada tiga bidang, memvalidasi bukti, menghasilkan penilaian terstruktur, menyimpan riwayat, menjaga isolasi data, dan menghapus hasil. Semua hasil HTTP 200 batch awal selesai di bawah target 60 detik. Namun kestabilan model belum memenuhi syarat final karena terdapat perubahan kecukupan pada DKV sedang dan kegagalan schema pada Marketing sedang. Validasi manusia juga belum tersedia. Oleh karena itu, status yang tepat adalah **prototipe fungsional dan layak didemonstrasikan secara terbatas, tetapi belum tervalidasi untuk klaim akurasi atau kesetaraan dengan penilai manusia.**

Hasil penilaian harus tetap disertai pernyataan:

Penilaian indikatif berdasarkan bukti yang dikirim dan rubrik Skillbridge AI. Hasil bukan verifikasi identitas, kepemilikan karya, kompetensi profesional, atau jaminan diterima kerja.