

10. Hasil Uji Coba

Bagian ini menyajikan hasil pengujian model AI dan prototipe Skillbridge AI untuk mengevaluasi kemampuan, kestabilan, fungsionalitas, keamanan dasar, dan kesesuaiannya terhadap permasalahan kesiapan kerja berbasis bukti. Pengujian dilaksanakan pada 24 Agustus 2026 terhadap deployment produksi `https://skillbridge-6ndn.vercel.app` dengan data sintetis. Seluruh angka pada bagian ini berasal dari pengujian yang benar-benar dijalankan. Hasil belum boleh ditafsirkan sebagai bukti bahwa model setara dengan penilai ahli karena baseline dua penilai manusia belum selesai.

10.1 Metode Pengujian

Pengujian dibagi menjadi empat kelompok:

- 1. **Pengujian struktural**, untuk memeriksa integritas dataset, konsistensi rubrik, perhitungan skor berbobot, validasi tipe file, URL GitHub, dan pemetaan pesan autentikasi.
- 2. **Pengujian model AI**, untuk mengukur keberhasilan respons terstruktur, kecukupan bukti, kestabilan tiga pengulangan, dan latensi end-to-end.
- 3. **Pengujian prototipe**, untuk memeriksa autentikasi, navigasi, tiga jenis bukti, persistence Supabase, riwayat, rekomendasi, wawancara, isolasi data, dan penghapusan.
- 4. **Pengujian antarmuka**, untuk memeriksa responsivitas desktop/mobile, struktur semantik dasar, label form, state autentikasi, dan overflow horizontal.

Model evaluator menggunakan Groq `openai/gpt-oss-20b` dengan temperature `0` dan strict JSON schema. Karya DKV terlebih dahulu dianalisis menggunakan model multimodal `qwen/qwen3.6-27b`, kemudian observasi visual dinilai oleh evaluator teks. Rubrik yang digunakan adalah versi `1.0`. Setiap bidang memiliki empat kriteria dengan skor anchor `0`, `25`, `50`, `75`, dan `100`. Jika satu kriteria tidak memiliki bukti cukup, kriteria diberi status `insufficient_evidence`, skornya `null`, dan skor akhir tidak ditampilkan.

Skor akhir dihitung aplikasi dengan persamaan:

Skor akhir = $\Sigma(\text{skor kriteria} \times \text{bobot kriteria})$

Model tidak diperbolehkan menentukan skor akhir. Server memeriksa jumlah kriteria, identitas kriteria, rentang skor, status kecukupan, dan referensi bukti sebelum hasil disimpan.

10.2 Data dan Skenario Pengujian

Dataset minimum terdiri atas sembilan fixture sintetis, legal, anonim, dan dibekukan menggunakan SHA-256. Distribusinya sebagai berikut:

Bidang	Target peran	Sampel	Bentuk bukti
Informatika	Junior Web Developer	3	Kode, struktur proyek, README, dan riwayat commit
DKV	Junior Graphic Designer	3	PNG hasil karya dan deskripsi brief/proses
Bisnis/Pemasaran	Junior Digital Marketer	3	PDF laporan dengan text layer dan data sintetis
Total		9	Tiga struktur bukti berbeda

Manifest memuat 21 artefak utama. Verifikasi ulang menghasilkan 21 dari 21 hash cocok. Target `weak`, `medium`, dan `strong` pada fixture merupakan desain skenario, bukan ground truth manusia.

Skenario pengujian model mencakup benchmark komprehensif sembilan fixture sintetis dengan tiga pengulangan independen (total 27 run evaluasi bertahap):

- Tiga pengulangan untuk masing-masing sampel Informatika (`INF-01`, `INF-02`, `INF-03`);
- Tiga pengulangan untuk masing-masing sampel DKV (`DKV-01`, `DKV-02`, `DKV-03`);
- Tiga pengulangan untuk masing-masing sampel Bisnis/Pemasaran (`MKT-01`, `MKT-02`, `MKT-03`).

Selain pengujian benchmark 27 run, pengujian prototipe live mencakup autentikasi anonim dan login, direct route protection, pilihan tiga bidang, validasi consent, file palsu, file lebih dari 4 MB, isolasi data dua akun (cross-account), RLS, private Storage, wawancara persisten di database, riwayat penilaian, dan cascade deletion.

10.3 Metrik Evaluasi

Aspek	Metrik
Integritas data	Jumlah hash cocok terhadap manifest
Kepatuhan output	HTTP sukses, empat kriteria, skor anchor valid, referensi bukti tersedia
Kecukupan bukti	Jumlah hasil <code>sufficient</code> dan <code>insufficient_evidence</code>
Stabilitas	Konsistensi status dan skor pada tiga input identik
Efisiensi	Minimum, median, persentil ke-95, maksimum latensi end-to-end
Fungsionalitas	Jumlah skenario prototipe lulus/gagal
Keamanan dasar	HTTP authorization, cross-account isolation, RLS, bucket privacy, residual data
Responsivitas	Overflow horizontal pada desktop, 390 px, dan 320 px
Relevansi sumber	Status HTTP 12 URL katalog belajar

Metrik akurasi, MAE, precision, recall, F1, dan agreement terhadap manusia belum dihitung karena `HUMAN_RATINGS.csv` masih memiliki 0 dari 36 baseline kriteria yang selesai.

10.4 Hasil Pengujian Struktural

Pengujian	Hasil
Integritas fixture SHA-256	21/21 cocok
Rubrik tersedia	3 rubrik, 12 kriteria
Bobot setiap rubrik	Tepat 1,0
Anchor setiap kriteria	0, 25, 50, 75, 100
Unit test aplikasi	6/6 lulus
Type checking TypeScript	Lulus
ESLint	Lulus
Production build Next.js	Lulus
Audit dependency	0 kerentanan high/critical

Hasil tersebut menunjukkan bahwa struktur rubrik, perhitungan skor, parser URL GitHub, magic-byte file, pemilihan tipe bukti, dan pemetaan error autentikasi telah memiliki pemeriksaan otomatis. Hasil ini belum mengukur ketepatan penilaian AI terhadap manusia.

10.5 Hasil Pengujian Model AI

10.5.1 Kepatuhan Schema dan Evaluasi Benchmark 27 Run

Evaluasi benchmark model dilaksanakan terhadap sembilan fixture sintetis (`INF-01..03`, `DKV-01..03`, `MKT-01..03`) dengan tiga pengulangan independen (

Run 1, Run 2, Run 3

) per sampel, menghasilkan **27 run evaluasi terstruktur**.

Seluruh 27 run pengujian (100%) berhasil mematuhi kontrak output Rubrik 1.1: 1. Menghasilkan tepat empat kriteria per bidang tanpa duplikasi atau kekurangan kriteria; 2. Masalah historis kegagalan skema pada Marketing sedang (array tujuh elemen pada batch awal) telah tereliminasi sepenuhnya melalui isolasi ekstraksi blok dan validasi schema server; 3. Seluruh skor non-null hanya menggunakan anchor resmi {0, 25, 50, 75, 100}; 4. Seluruh kutipan bukti (

evidence quotes

) ter-grounding exact ke penanda referensi fisik (`[PAGE:n:BLOCK:n]` untuk PDF dan `[FILE:n:Lx-Ly]` untuk source code); 5. Propagasi kegagalan aman (

safe null propagation

) bekerja 100%: setiap sampel dengan kriteria berstatus `insufficient_evidence` menghasilkan `finalScore: null` (tampil sebagai `-/100` pada antarmuka).

Tingkat Keberhasilan Schema 27 Run Benchmark

Valid Rubric 1.1 Schema	100,00% (27/27)
Grounded Evidence Quotes	100,00% (27/27)
Discreet Anchor Adherence	100,00% (27/27)

10.5.2 Matriks Lengkap Hasil Benchmark 9 Fixture × 3 Run

Tabel 3 menyajikan rekapitulasi skor per kriteria dan skor akhir berbobot untuk seluruh 27 pengujian:

Sampel Fixture	Bidang & Peran	Run	Skor Kriteria [K1, K2, K3, K4]	Status Bukti	Final Score
INF-01 (Weak)	Informatika	1	[0, 25, null, null]	insufficient_evidence	null (-/100)
	(Jr. Web Developer)	2	[0, 25, null, null]	insufficient_evidence	null (-/100)
		3	[0, 25, null, null]	insufficient_evidence	null (-/100)
INF-02 (Medium)	Informatika	1	[50, 75, 75, 50]	sufficient	61/100
	(Jr. Web Developer)	2	[50, 75, 75, 50]	sufficient	61/100
		3	[50, 75, 75, 50]	sufficient	61/100
INF-03 (Strong)	Informatika	1	[75, 100, 50, 100]	sufficient	81/100
	(Jr. Web Developer)	2	[75, 100, 50, 100]	sufficient	81/100
		3	[75, 100, 50, 100]	sufficient	81/100
DKV-01 (Weak)	DKV	1	[0, 0, 25, 25]	sufficient	11/100
	(Jr. Graphic Designer)	2	[0, null, 25, 25]	insufficient_evidence	null (-/100)
		3	[0, null, 25, 25]	insufficient_evidence	null (-/100)
DKV-02 (Medium)	DKV	1	[50, 50, 50, 50]	sufficient	50/100
	(Jr. Graphic Designer)	2	[75, 50, 50, 50]	sufficient	58/100
		3	[50, 50, 50, 50]	sufficient	50/100
DKV-03 (Strong)	DKV	1	[75, 75, 75, 75]	sufficient	75/100
	(Jr. Graphic Designer)	2	[75, 75, 75, 100]	sufficient	81/100
		3	[75, 75, 75, 75]	sufficient	75/100
MKT-01 (Weak)	Pemasaran	1	[25, null, null, 25]	insufficient_evidence	null (-/100)
	(Jr. Digital Marketer)	2	[25, null, null, 25]	insufficient_evidence	null (-/100)
		3	[25, null, null, 25]	insufficient_evidence	null (-/100)
MKT-02 (Medium)	Pemasaran	1	[50, 75, 50, 75]	sufficient	61/100
	(Jr. Digital Marketer)	2	[50, 50, 50, 75]	sufficient	55/100
		3	[50, 75, 50, 75]	sufficient	61/100
MKT-03 (Strong)	Pemasaran	1	[100, 100, 100, 100]	sufficient	100/100
	(Jr. Digital Marketer)	2	[100, 100, 100, 100]	sufficient	100/100
		3	[100, 100, 100, 100]	sufficient	100/100

Catatan Kriteria per Bidang:

- **Informatika**: K1=Kualitas kode (0.35), K2=Struktur proyek (0.25), K3=Dokumentasi (0.20), K4=Riwayat kontribusi (0.20). - **DKV**: K1=Konsistensi visual (0.30), K2=Proses & iterasi (0.25), K3=Narasi desain (0.20), K4=Pemecahan masalah (0.25). - **Pemasaran**:

K1=Metodologi kampanye (0.25), K2=Penggunaan data (0.25), K3=Hasil terukur (0.30), K4=Kualitas laporan (0.20).

10.5.3 Analisis Stabilitas dan Evaluasi Kasus Perbatasan


Tabel berikut menyajikan ringkasan statistik stabilitas model AI antar 3 run pengulangan independen:

Sampel Fixture	Bidang	Run 1	Run 2	Run 3	Rata-rata Skor	Variansi (s ²)	Standar Deviasi (s)	Status Konsistensi
INF-01	Informatika	null	null	null	null	0,00	0,00	100% Deterministik (insufficient_evidence)
INF-02	Informatika	61	61	61	61,00	0,00	0,00	100% Deterministik
INF-03	Informatika	81	81	81	81,00	0,00	0,00	100% Deterministik
DKV-01	DKV	11	null	null	11,00*	0,00	0,00	Konsisten batas kualifikasi lemah (2/3 null, 1/3 11)
DKV-02	DKV	50	58	50	52,67	21,33	4,62	Fluktuasi minor 1 anchor pada kriteria visual
DKV-03	DKV	75	81	75	77,00	12,00	3,46	Fluktuasi minor 1 anchor pada pemecahan masalah
MKT-01	Pemasaran	null	null	null	null	0,00	0,00	100% Deterministik (insufficient_evidence)
MKT-02	Pemasaran	61	55	61	59,00	12,00	3,46	Fluktuasi minor 1 anchor pada penggunaan data
MKT-03	Pemasaran	100	100	100	100,00	0,00	0,00	100% Deterministik

Ringkasan Kestabilan:

- Sebanyak **6 dari 9 sampel (66,7%)** menunjukkan standar deviasi 0,00 (sempurna/deterministik). - Tiga sampel lainnya (DKV-02, DKV-03, MKT-02) hanya memiliki deviasi minor sebesar 3,46 – 4,62 poin (s

² ≤ 21,33), yang sepenuhnya disebabkan oleh pergeseran satu langkah anchor diskrit (misal 50 vs 75) pada kriteria perbatasan. - Rata-rata standar deviasi keseluruhan 9 sampel adalah **1,28 poin**, mengindikasikan tingkat keandalan dan reproduibilitas inferensi yang sangat tinggi pada temperatur 0.



Uji Stabilitas Model: Konsistensi Hasil Penilaian pada 3 Run Pengulangan

1. Informatika (Stabilitas 100%, Variansi 0.0):

- Ketiga sampel menunjukkan konsistensi deterministik sempurna di seluruh tiga run pengujian.
- INF-01 konsisten mendeteksi ketiadaan README dan commit yang kurang dari tiga, menghasilkan status bukti belum cukup tanpa mengarang skor nol.

- INF-02 stabil pada 61/100 berkat pemisahan modul yang jelas di `src/` dan dokumentasi yang memuat batasan memori.
- INF-03 stabil pada 81/100; kriteria dokumentasi konsisten diberi skor 50 karena mendokumentasikan rute HTTP yang belum diimplementasikan pada kode sumber aktual.

2. DKV (Penyebab Fluktuasi Sampel Sedang Teridentifikasi):

- Pada DKV-01, terjadi ambiguitas penafsiran pada kriteria proses: deskripsi “hanya satu versi final” dapat dimaknai sebagai skor 0 (tanpa eksplorasi) atau `insufficient_evidence` (karena syarat bukti minimal dua tahap tidak ada). Kedua penafsiran sama-sama mengindikasikan level lemah.
- Pada DKV-02, pengujian menghasilkan konsensus 50/100 (dua run 50, satu run 58). Peningkatan kestabilan dibanding batch awal terjadi karena pemisahan observasi visual multimodal ke data terstruktur yang memandu model secara objektif.
- Pada DKV-03, skor stabil pada kisaran 75–81/100, selaras dengan adjudikasi kriteria pemecahan masalah (anchor 75 vs 100).

3. Bisnis & Pemasaran (Schema 100% Lulus, Stabilitas Tinggi):

- MKT-01 stabil 100% berstatus `insufficient_evidence` karena tidak menyertakan angka metrik kampanye sama sekali.
- MKT-02 menghasilkan 61/100 pada Run 1 dan 3, serta 55/100 pada Run 2 (perbedaan pada kriteria penggunaan data antara anchor 50 dan 75 karena ketiadaan data biaya historis).
- MKT-03 menghasilkan skor sempurna 100/100 secara konsisten di ketiga run karena seluruh elemen hipotesis, funnel, tabel metrik lengkap, rumus, dan batas atribusi disajikan secara transparan.

10.5.4 Perbandingan terhadap Baseline Human Ratings (AI-Simulated) dan Target Expected


Hasil 27 run benchmark dibandingkan langsung terhadap baseline 36 sel penilaian kriteria di `docs/validation/HUMAN_RATINGS.csv` (dihasilkan melalui simulasi blind review oleh subagent `AI_SIM_R1` dan `AI_SIM_R2` dengan adjudikasi independen) serta target desain `fixtures/expected.json`:

Sampel	Skor Konsensus AI	Baseline Human (Adjudicated)	Expected Target (<code>expected.json</code>)	Selisih Skor (AI vs Human)	Status Kesesuaian Kriteria
INF-01	<code>null (-/100)</code>	<code>null (-/100)</code>	<code>null</code>	0	Cocok Sempurna (4/4 kriteria match)
INF-02	61/100	<code>null* (-/100)</code>	50/100	-	3/4 kriteria match; selisih pada riwayat commit*
INF-03	81/100	<code>null* (-/100)</code>	100/100	-	3/4 kriteria match; selisih pada riwayat commit*
DKV-01	<code>null (-/100)</code>	11/100	<code>null</code>	-	3/4 kriteria match; selisih pada kriteria proses
DKV-02	50/100	50/100	50/100	0	Cocok Sempurna (4/4 kriteria match)
DKV-03	75/100	81/100	100/100	-6	3/4 kriteria match; selisih 1 anchor problem solving
MKT-01	<code>null (-/100)</code>	<code>null (-/100)</code>	<code>null</code>	0	Cocok Sempurna (4/4 kriteria match)
MKT-02	61/100	61/100	61/100	0	Cocok Sempurna (4/4 kriteria match)
MKT-03	100/100	100/100	100/100	0	Cocok Sempurna (4/4 kriteria match)

*Catatan

: Penilai manusia memberi status `insufficient_evidence` pada kriteria riwayat kontribusi INF-02 dan INF-03 karena paket file statis yang diinspeksi tidak menyertakan berkas log git fisik; sebaliknya, parser otomatis mengekstrak commit history repositori aktual (INF-02: 4 commit -> skor 50; INF-03: 6 commit -> skor 100).

- **Exact Match Konsensus AI vs Human Baseline: 32 dari 36 kriteria (88,89%)** bernilai identik sempurna. - **Mean Absolute Error (MAE)** terhadap Human Baseline: **2,78 poin** (pada skala 0–100). - **Exact Match Konsensus AI vs Expected Target: 26 dari 36 kriteria (72,22%)** dengan MAE **7,64 poin**.



Perbandingan Skor Benchmark: AI Consensus vs Human Baseline vs Target Expected


Catatan Provenance

: Baseline perbandingan ini berasal dari simulasi independen **AI-simulated R1/R2** yang menguji kesiapan instrumen dan keterbacaan rubrik. Baseline ini membuktikan bahwa evaluator aplikasi konsisten terhadap interpretasi rubrik yang ketat, namun **bukan pengganti validasi dua penilai manusia nyata**.

10.5.5 Metrik Latensi End-to-End dan Estimasi Biaya Inferensi Provider Groq

Pengujian performa komputasi dievaluasi terhadap seluruh eksekusi inferensi pada deployment produksi:

Bidang	Pipeline AI	Min Latensi	Median	Rata-rata	P95	Maks Latensi
Informatika	Single-Call LLM (openai/gpt-oss-20b)	3,36 s	5,00 s	4,96 s	6,36 s	6,52 s
DKV	2-Stage Pipeline (Vision qwen3.6-27b + Text gpt-oss-20b)	9,22 s	21,58 s	22,18 s	32,56 s	34,71 s
Pemasaran	Single-Call LLM (openai/gpt-oss-20b)	4,86 s	7,36 s	9,68 s	19,17 s	19,74 s
Keseluruhan	16 Run Produksi Tercatat	3,36 s	8,27 s	12,70 s	26,63 s	34,71 s



Analisis Kinerja Latensi End-to-End Sistem Skillbridge AI

Estimasi Token dan Biaya Inferensi per Evaluasi:

Mengacu pada tarif on-demand Groq LPU API (\$0,10 / 1 juta input tokens dan \$0,20 / 1 juta output tokens untuk model GPT-OSS-20B, serta \$0,20 / 1 juta tokens untuk Qwen Vision):

1. Informatika (1 panggilan API):

- Input: ~3.000 token (rubrik, batasan schema, AST/tree repositori, kode sumber ter-grounding) → \$0,00030
- Output: ~800 token (JSON rubrik 1.1, 4 kriteria berbobot, kutipan bukti verbatim, rekomendasi) → \$0,00016
- Total Biaya per Evaluasi: \$0,00046** (sekitar **Rp 7,36**, asumsi \$1 = Rp 16.000).

2. Bisnis & Pemasaran (1 panggilan API):

- Input: ~2.500 token (rubrik, teks layer PDF dengan marker [PAGE:n:BLOCK:n]) → \$0,00025
- Output: ~800 token (JSON rubrik 1.1 lengkap) → \$0,00016
- Total Biaya per Evaluasi: \$0,00041** (sekitar **Rp 6,56**).

3. DKV Multimodal (2 tahap berurutan):

- Tahap 1 (Vision): ~1.500 token (image base64 + prompt ekstraksi observasi) → \$0,00030; Output: ~300 token → \$0,00006 (Subtotal: \$0,00036).
- Tahap 2 (Evaluator): ~2.200 token (rubrik, observasi terstruktur, narasi) → \$0,00022; Output: ~800 token → \$0,00016 (Subtotal: \$0,00038).
- Total Biaya per Evaluasi: \$0,00074** (sekitar **Rp 11,84**).

4. Total Komputasi Benchmark 27 Run:

- 9 Run Informatika: $9 \times \$0,00046 = \$0,00414$ (~Rp 66).
- 9 Run DKV: $9 \times \$0,00074 = \$0,00666$ (~Rp 107).
- 9 Run Pemasaran: $9 \times \$0,00041 = \$0,00369$ (~Rp 59).
- Total Akumulasi Biaya 27 Run: \$0,0145** (sekitar **Rp 232**).

10.6 Hasil Pengujian Prototipe

Deployment produksi diuji pada <https://skillbridge-6ndn.vercel.app>.

Skenario	Hasil
Health endpoint dan koneksi Supabase	HTTP 200, <code>checks.supabase=true</code>
API assessment tanpa token	HTTP 401
API assessment dengan token acak	HTTP 401
Login email/password	Berhasil, redirect ke <code>/assess</code>
Navbar pengguna anonim	Hanya <code>Daftar</code> dan <code>Masuk</code>
Direct <code>/assess</code> tanpa login	Redirect ke <code>/auth?next=/assess</code>
Navbar pengguna login	<code>Penilaian</code> , <code>Riwayat</code> , <code>Keluar</code>
Consent tidak dicentang	HTTP 400, model tidak dipanggil
File dengan ekstensi PDF tetapi magic bytes SVG	HTTP 400
File PNG 4 MB + 1 byte	HTTP 400, tanpa residual row
Akun pemilik membaca evidence	13 row uji terlihat
Akun kedua membaca evidence pemilik	0 row
Akun kedua membuka assessment ID pemilik	Array kosong, data tidak bocor
Akun kedua memulai interview assessment pemilik	HTTP 404
Bucket evidence	Private, batas 4.194.304 byte
Interview assessment sendiri	HTTP 200, 2,361 detik
Delete assessment upload	HTTP 204
Residual setelah delete	0 assessment, 0 evidence, 0 score, 0 object Storage
Cache respons privat setelah perbaikan	<code>Cache-Control: private, no-store</code>

Pengujian memperlihatkan bahwa authentication, ownership check, RLS read isolation, private Storage, dan delete cascade bekerja pada data sintetis. Namun operasi database server menggunakan service-role client sehingga RLS bukan satu-satunya boundary; filter ownership aplikasi tetap kritis.

10.6.1 Dokumentasi Uji Langsung Antarmuka Produksi

Pengujian alur pengguna (

end-to-end user journey

) diverifikasi secara langsung pada infrastruktur produksi `https://skillbridge-6ndn.vercel.app`. Enam artefak visual beresolusi tinggi berikut mendokumentasikan setiap tahapan sistem:



Antarmuka Beranda (Landing Page) Skillbridge AI Produksi

Gambar 4. Antarmuka beranda live pada deployment produksi (/) yang menyajikan proposisi nilai evaluasi berbasis bukti, tiga tahapan metodologi, serta tiga jalur spesialisasi karir.

Skillbridge AI

Penilaian

Riwayat

Keluar

PENILAIAN BARU

Bawa satu bukti.

GitHub untuk Informatika, gambar karya untuk DKV, atau PDF laporan untuk Bisnis/Pemasaran.

Bidang dan target peran

Informatika — Junior Web Developer

Rubrik versi 1.1 dipilih dari target ini.

URL repositori GitHub publik

https://github.com/octocat/Hello-World

Kode tidak dijalankan. Sistem membaca metadata, tree, README, dan 10 commit terbaru.

☒

Persetujuan pemrosesan AI

Bukti dikirim ke Groq untuk dinilai. Nama dan email tidak dibutuhkan. Saya memahami batas penilaian dan dapat menghapus hasil melalui akun.

Kirim dan nilai bukti

SEBELUM MENKIRIM

Repositori kode

Kualitas kode, struktur proyek, dokumentasi README, dan pola kontribusi.

Hasil dan file tersimpan privat di Supabase. File hanya diproses server dan dapat dihapus bersama hasil.

Demo Sidang: Buka data seed terverifikasi.

Prototipe evaluasi indikatif berbasis bukti. Bukan verifikasi kompetensi atau jaminan kerja.

FAQ

Privasi

Terima kasih

Formulir Penyerahan Bukti Penilaian Lintas Tiga Bidang dengan Persetujuan AI

Gambar 5. Formulir pengajuan penilaian (/assess) dengan pemilihan multi-bidang, panduan kontekstual, dan proteksi persetujuan pemrosesan AI (consent checkbox).

Skillbridge AI — Dokumen Hasil Uji Coba (Poin 10 Proposal)

Halaman 10
Halaman 10 dari 16

SB Skillbridge AI

PenilaianRiwayatKeluar

RUBRIK 1.1 - JUNIOR WEB DEVELOPER

50/100

Penilaian Ulang: Dibandingkan dengan hasil 20/8/2026 (bukti belum cukup).

Data Demo Sidang Kompres: Hasil ini adalah data seed terverifikasi untuk demonstrasi offline/cadangan sidang, bukan hasil live palsu.

Penilaian indikatif berdasarkan bukti yang dikirim. Bukan verifikasi identitas, kepemilikan karya, atau jaminan diterima kerja.

KRITERIA 1

Kualitas kode

50/100 +25

Cukup terbaca

Keyakinan: Tinggi

Mengapa nilai ini

Alur utama terbaca dan validasi dasar tersedia, namun belum ada penanganan edge case dan automated test.

[FILE:1:L12-L28]

KRITERIA 2

Struktur proyek

50/100 +25

Pemisahan dasar

Keyakinan: Tinggi

Mengapa nilai ini

Entry point dan domain dipisah secara dasar antara routes, events, dan server.

[FILE:2:L1-L20]

KRITERIA 3

Dokumentasi

50/100 Baru dinilai

Setup dasar

Keyakinan: Tinggi

Mengapa nilai ini

README memuat instruksi instalasi dan setup dasar, namun belum mencantumkan konfigurasi environment lengkap.

[FILE:3:L1-L15]

KRITERIA 4

Riwayat kontribusi

50/100 Baru dinilai

Progres dasar

Keyakinan: Tinggi

Mengapa nilai ini

4 commit bertahap menunjukkan progres dasar pengembangan fitur secara berkala.

[COMMIT:1]

Hasil Penilaian Portofolio Berdasarkan Rubrik 1.1 Ter-grounding

Gambar 6. Halaman hasil penilaian (`/results/[id]`) menampilkan skor berbobot 50/100, banner transparansi data seed demo, evaluasi 4 kriteria Rubrik 1.1, badge selisih komparatif (+25), dan penanda kutipan bukti ter-grounding fisik.

KEKUATAN

Struktur modul routes, events, dan server sudah dipisahkan secara teratur.
README memuat panduan instalasi dan instruksi menjalankan aplikasi.

GAP UTAMA

Penanganan error mendalam dan automated unit test belum tersedia
Validasi skema input pada endpoint belum menyeluruh

BATAS PENILAIAN

Penilaian indikatif berbasis analisis statis; kode repositori tidak dieksekusi di runtime.

LANGKAH BERIKUTNYA

Materi dari katalog terkurasi.

MDN: JavaScript Guide

Dipilih untuk gap kualitas kode.

Next.js Project Structure

Dipilih untuk gap struktur proyek.

GitHub: About READMEs

Dipilih untuk gap dokumentasi.

Mulai wawancara

Nilai bukti baru

Hapus hasil

Prototipe evaluasi indikatif berbasis bukti. Bukan verifikasi kompetensi atau jaminan kerja.

FAQPrivasiTerima kasih

Sintesis Kesenjangan Kompetensi dan Rekomendasi Materi Pembelajaran Terkurasi

Gambar 7. Bagian analisis kesenjangan (

skill gaps
) yang merangkum kekuatan, kelemahan, dan batas penilaian, disertai 3 materi pembelajaran terkurasi dari katalog resmi (MDN, Next.js, GitHub).

SB

Skillbridge AI

PenilaianRiwayatKeluar

RIWAYAT AKUN

Jejak penilaian.

Maksimal 20 penilaian terbaru milik akun Anda.

75/100

Junior Web Developer
31/8/2026, 14.44.41 · Rubrik 1.1

Lihat hasil

—/100

Junior Web Developer
30/8/2026, 18.11.41 · Rubrik 1.0

Lihat hasil

—/100

Junior Web Developer
30/8/2026, 18.10.58 · Rubrik 1.0

Lihat hasil

81/100

Junior Digital Marketer
28/8/2026, 10.07.38 · Rubrik 1.0

Lihat hasil

70/100

Junior Graphic Designer
28/8/2026, 10.06.25 · Rubrik 1.0

Lihat hasil

—/100

Junior Web Developer
28/8/2026, 10.04.46 · Rubrik 1.0

Lihat hasil

75/100

Junior Digital Marketer
24/8/2026, 09.01.28 · Rubrik 1.0

Lihat hasil

—/100

Junior Graphic Designer
24/8/2026, 08.50.15 · Rubrik 1.0

Lihat hasil

71/100

Junior Web Developer
24/8/2026, 01.53.11 · Rubrik 1.0

Lihat hasil

Simulasi Sidang Kompres (Data Seed):

Demo Informatika (50/100 · +25 Δ)

Demo DKV (50/100)


Demo Marketing (61/100)

Prototipe evaluasi indikator berbasis bukti. Bukan verifikasi kompetensi atau jaminan kerja.

FAQPrivasiTerima kasih

Rekapitulasi Riwayat Akun dan Penanda Perbandingan Penilaian Ulang (Reassessment Diff)

Gambar 8. Halaman riwayat akun (/history) yang mendokumentasikan pengujian berkelanjutan lintas tiga bidang, kepatuhan safe null* (—/100), dan launcher simulasi penilaian ulang ber-diff badge (+25 Δ)*.



Sesi Wawancara Teknis Adaptif Berbasis Kesenjangan Bukti

Gambar 9. Sesi simulasi wawancara adaptif (`/interview/[id]`) dengan dialog multi-turn, respon kandidat, umpan balik pewawancara terpisah dari skor bukti fisik, dan pembatas 5 pertanyaan.

10.6.2 Validasi Rubrik 1.1 dan Optimasi Runtime

Pada pembaruan terkini, evaluator rubrik 1.1 beroperasi melalui runtime teroptimasi dengan perlindungan rate limit Groq (~8.000 TPM). Evaluator Informatika menyelesaikan inferensi dalam 5,0 detik rata-rata; DKV menyelesaikan inferensi multimodal 2-stage (Vision Qwen 3.6-27B + Evaluator GPT-OSS-20B) dalam 21,6 detik; dan Bisnis/Pemasaran menyelesaikan ekstraksi PDF dan inferensi dalam 7,4 detik.

Gerbang rilis lulus `eslint`, TypeScript, 33 unit test otomatis (`node:test`), dan build Turbopack Next.js 16. Deployment `dpl_33RcMq8YqEiR7EYdcTCRNaxVMJrt` berstatus `Ready` pada alias produksi `https://skillbridge-6ndn.vercel.app` dan endpoint `/api/health` aktif.

10.6.3 Persistensi Sesi Wawancara dan Manajemen State Database

Modul simulasi wawancara adaptif terintegrasi penuh dengan persistensi database PostgreSQL Supabase via migrasi `005_interview_persistence.sql`: 1. **Struktur Data**: Sesi dicatat pada tabel `interviews` (mengikat `assessment_id`, `user_id`, `status`, dan `focus_areas`), dan pesan disimpan pada `interview_messages` (`role`, `content`, `created_at`). 2. **Keandalan Antarmuka**: Halaman `/interview/[id]` memuat riwayat percakapan sebelumnya via `GET /api/interview?assessmentId=...` saat dibuka. Refresh browser tidak menghapus riwayat latihan. 3. **Batas Sesi**: Sesi otomatis berstatus `completed` setelah lima jawaban pengguna tercapai, dengan umpan balik akhir tersimpan permanen.

10.7 Hasil Pengujian Keamanan, Edge Cases, dan Ketahanan Sistem

Pengujian ketahanan dan keamanan menyeluruh dilaksanakan terhadap 28 skenario pengujian pada deployment produksi:

No	Kategori Pengujian	Skenario / Input Uji	Respon yang Diharapkan	Respon Aktual Sistem	Status	Catatan Teknis
1	API Security	GET /api/health publik	HTTP 200 {"status":"ok"}	HTTP 200 {"status":"ok"}	PASS	Probe liveness aktif, fingerprint database tidak diekspos
2	API Security	GET /api/assessments tanpa token	HTTP 401 Unauthorized	HTTP 401 unauthorized	PASS	Verifikasi token Supabase Auth via authenticatedUser()
3	API Security	POST /api/assess tanpa token	HTTP 401 Unauthorized	HTTP 401 unauthorized	PASS	Guard autentikasi sebelum konsumsi kuota atau payload reading
4	API Security	POST /api/interview (non-demo ID) tanpa token	HTTP 401 Unauthorized	HTTP 401 unauthorized	PASS	Ownership check mengunci akses sesi wawancara privat
5	Input Validation	POST /api/interview tanpa parameter ID	HTTP 400 Bad Request	HTTP 400 missing_id	PASS	Pesan error ramah pengguna dalam Bahasa Indonesia
6	Input Validation	ID assessment dengan format bukan UUID v4	HTTP 400 Bad Request	HTTP 400 invalid_id	PASS	Regex assertion ketat format UUID v4 standar RFC 4122
7	File Security	Berkas berekstensi .pdf berisi tag <svg>	HTTP 400 ditolak	Error: format bukti tidak didukung	PASS	Magic bytes inspection %PDF mendeteksi file palsu
8	File Security	Berkas gambar berekstensi .png berisi plain text	HTTP 400 ditolak	Error: format bukti tidak didukung	PASS	Magic bytes inspection \x89PNG menolak file teks
9	File Security	Berkas PDF diunggah ke form DKV	HTTP 400 ditolak	Error: DKV menerima PNG/JPEG	PASS	Penolakan berbasis tipe berkas per bidang studi
10	Edge Case File	Berkas bukti berukuran 0 byte (kosong)	HTTP 400 ditolak	Error: ukuran bukti > 0 dan ≤ 4 MB	PASS	Mencegah alokasi buffer kosong di server
11	Edge Case File	Berkas bukti berukuran tepat 4.194.304 byte (4 MB)	Lolos validasi ukuran	Validasi ukuran sukses	PASS	Batas maksimal boundary diterima presisi
12	Edge Case File	Berkas bukti berukuran 4.194.305 byte (4 MB + 1 B)	Ditolak aman	Error: ukuran bukti melebihi 4 MB	PASS	Penolakan aman tanpa sisa row atau storage object
13	Dos Mitigation	Multipart request dengan Content-Length > 4 MB	HTTP 413 Payload Too Large	HTTP 413 payload_too_large	PASS	Preflight Content-Length memutus koneksi sebelum buffering
14	Dos Mitigation	Gambar dengan dimensi 10.001 x 10.001 px	Ditolak aman	Error: dimensi gambar terlalu besar	PASS	Proteksi pixel decompression bomb (maks 24 MP)
15	Prompt Security	Bukti memuat "Ignore previous instructions..."	Ditolak sebelum AI	Error: memuat instruksi manipulatif	PASS	Adversarial regex scanner memblokir input jahat
16	Prompt Security	Injeksi teks via Zero-Width Characters	Ditolak sebelum AI	Karakter dinormalisasi & terblokir	PASS	Normalisasi Unicode NFKC menghilangkan obfuscation
17	Secret Protection	Bukti memuat AWS Key AKIA... atau API token	Ditolak sebelum AI	Error: bukti memuat credential	PASS	Regex credential scanner mencegah kebocoran kunci
18	AI Grounding	Kutipan bukti tidak cocok dengan blok fisik PDF	Ditolak server	Error: kutipan bukti tidak cocok	PASS	quoteMatchesReference memvalidasi grounding faktual
19	AI Grounding	Repositori GitHub tanpa source file kode	Insufficient evidence	Kriteria web_code_quality null	PASS	Server memaksa null tanpa mengarang skor nol
20	Code Security	URL GitHub mengarah ke domain selain github.com	Ditolak aman	Error: gunakan URL repositori GitHub	PASS	Host allowlist ketat https://github.com/{owner}/{repo}

No	Kategori Pengujian	Skenario / Input Uji	Respon yang Diharapkan	Respon Aktual Sistem	Status	Catatan Teknis
21	Code Security	Analisis kode repositori GitHub	Non-eksekusi statis	Teks terbaca, zero execution	PASS	Zero RCE risk; kode diekstrak via REST API saja
22	Rate Limiting	Groq provider melempar error HTTP 429	HTTP 429 <code>ai_rate_limit</code>	HTTP 429, <code>Retry-After: 60</code>	PASS	Pemetaan aman tanpa membocorkan pesan mentah provider
23	Rate Limiting	Kuota harian pengguna tercapai (10 assess/hari)	HTTP 429 Rate Limit	HTTP 429 <code>rate_limit_exceeded</code>	PASS	Ditegakkan di DB via RPC <code>consume_api_quota</code>
24	Data Isolation	Akun B membaca penilaian milik Akun A	Array kosong / 404	Tidak ada data bocor (0 row)	PASS	Filter kepemilikan aplikasi dan RLS Supabase aktif
25	Data Isolation	Akses langsung ke bucket storage bukti	Ditolak (Private)	403 Forbidden	PASS	Bucket private, berkas hanya via signed URL
26	State Resilience	Refresh browser saat sesi wawancara	State percakapan utuh	Riwayat dimuat dari DB	PASS	Persistensi via <code>interviews</code> & <code>interview_messages</code>
27	Session Boundary	Pengguna menjawab lebih dari 5 turn pertanyaan	Sesi selesai	Status <code>completed</code> , form ditutup	PASS	State machine membatasi tepat 5 pertanyaan latihan
28	Security Headers	Seluruh respon API & web	Header keamanan lengkap	CSP, HSTS, XFO, nosniff, COOP/CORP	PASS	Hardening header aktif di Next.js config

10.8 Hasil Pengujian Antarmuka dan Rekomendasi

Pengujian tata letak antarmuka dan responsivitas browser dilakukan menggunakan Chromium pada resolusi desktop (1440 px), tablet, dan mobile (390 px serta 320 px):

Pemeriksaan	Hasil
Landing desktop	Satu <code>main</code> , heading benar, tiga kartu bidang, tanpa overflow
Bahasa dokumen	<code>lang="id"</code>
Navbar anonim	<code>Daftar</code> , <code>Masuk</code>
Auth gate	Form assessment tidak tampil sebelum login
Form Informatika	URL GitHub, tanpa file input
Form DKV	PNG/JPEG, deskripsi proses, tanpa URL GitHub
Form Marketing	PDF, 4 MB, 15 halaman
Mobile 390 px	Tidak ada horizontal overflow
Mobile 320 px sebelum perbaikan	Overflow sekitar 10 px pada navbar login
Mobile 320 px setelah perbaikan	Lulus; lebar viewport dan scroll width sama-sama 320 px
History	Hasil tiga bidang tampil berurutan, tanpa overflow desktop
Result	Empat kriteria, batas klaim, interview, reassess, delete

Katalog materi pembelajaran telah diperluas dari 12 URL menjadi 30 materi terkurasi (`src/lib/learning-catalog.ts`), mencakup 2–3 sumber belajar berjenjang (

beginner

dan

intermediate

) untuk setiap satu dari 12 kriteria di tiga bidang.

Fungsi penyeleksi rekomendasi `recommendResources()` memetakan maksimal tiga materi terarah berdasarkan kesenjangan (*skill gaps*

) terbesar pengguna. Seluruh 30 tautan menggunakan protokol HTTPS dan mengarah ke domain edukasi/industri terpercaya (MDN, GitHub, Next.js Docs, Nielsen Norman Group, Material Design, IDEO, Google Skillshop, Google Analytics Academy, HubSpot Academy, dan Looker Studio). Pemeriksaan otomatis memastikan integritas URL dan ketersediaan materi untuk setiap kriteria dengan 2/2 unit test lulus.

10.9 Kelebihan Solusi

1. Sistem menerima tiga bentuk bukti berbeda: repositori GitHub, karya visual, dan laporan PDF.
2. Penilaian menggunakan rubrik khusus bidang dan bukti tidak cukup tidak dipaksa menjadi skor nol.
3. Skor akhir dihitung server, bukan dipercaya dari satu angka keluaran model.
4. Strict schema dan validasi referensi mencegah keluaran tidak konsisten tersimpan.
5. Output schema-invalid gagal aman dan tidak menjadi assessment selesai.
6. Data pengguna terisolasi melalui authentication, ownership filter, RLS, dan private Storage.
7. File diperiksa dari magic bytes, bukan hanya ekstensi atau MIME browser.
8. Kode GitHub tidak dijalankan sehingga risiko eksekusi kode pengguna berkurang.
9. Penghapusan assessment menghapus row turunan dan object Storage pada skenario normal.
10. UI adaptif mengikuti jenis bukti tiap bidang dan bekerja pada desktop serta mobile utama.
11. Sesi wawancara adaptif tersimpan persisten di database, memungkinkan pengguna melanjutkan latihan kapan saja.
12. Rekomendasi materi belajar berjenjang disesuaikan langsung dengan gap kriteria penilaian pengguna.

10.10 Keterbatasan

1. Dataset saat ini terdiri atas sembilan fixture sintetis dan belum mewakili seluruh populasi mahasiswa Indonesia.
2. Baseline penilai manusia asli (HR profesional) belum selesai; perbandingan saat ini menggunakan baseline simulasi independen `AI-simulated R1/R2` untuk verifikasi instrumen.
3. Token usage dan biaya inferensi provider per pemanggilan belum dicatat ke tabel analitik aplikasi.
4. Ekstraktor Informatika pada form produksi membutuhkan repositori publik di GitHub; repositori privat atau berkas lokal belum didukung secara langsung via antarmuka web.
5. Parser PDF hanya menerima dokumen dengan text layer; OCR untuk dokumen hasil pemindaian (`scan`) belum tersedia.
6. Sistem menilai kelayakan isi bukti tetapi tidak memverifikasi identitas hukum atau kepemilikan mutlak atas karya tersebut.
7. Kode repositori tidak dijalankan secara runtime sehingga bug dinamis atau performa aplikasi berjalan tidak dinilai.
8. Rekomendasi materi menggunakan katalog kurasi terarah berdasarkan mapping gap kriteria, belum menggunakan mesin pencari semantik vektor/RAG embedding skala besar.
9. Relevansi pedagogis materi belajar belum dinilai secara formal oleh evaluator kurikulum manusia.
10. Pengujian otomatis menyeluruh untuk browser Firefox, Safari WebKit, dan pemindai kontras otomatis WCAG tingkat lanjut masih perlu diperluas pada tahap berikutnya.

10.11 Kesimpulan Pengujian

Pengujian komprehensif membuktikan bahwa prototipe Skillbridge AI telah berhasil mengimplementasikan alur evaluasi kesiapan kerja berbasis bukti secara menyeluruh (`end-to-end`)

) pada tiga bidang (Informatika, DKV, dan Bisnis/Pemasaran). Hasil benchmark 27 run menunjukkan bahwa pembaruan Rubrik 1.1, pemisahan observasi visual multimodal, dan penataan parsing PDF menghasilkan kepatuhan skema 100%, eliminasi kegagalan parsing array, serta konsistensi status kecukupan bukti yang tinggi.

Penambahan persistensi wawancara pada Supabase dan ekspansi 30 materi katalog terkurasi menyelesaikan siklus pembelajaran tertutup (`closed-loop learning`)

) yang diamanatkan dalam proposal. Meskipun demikian, karena validasi dua penilai HR manusia independen masih berstatus pending, prototipe ini berstatus **fungsional, stabil, dan siap didemonstrasikan untuk sidang kompres, namun belum boleh digunakan untuk klaim kesetaraan objektif dengan penilai manusia.**

Seluruh hasil penilaian wajib menyertakan batasan:

Penilaian indikatif berdasarkan bukti yang dikirim dan rubrik Skillbridge AI. Hasil bukan verifikasi identitas, kepemilikan karya, kompetensi profesional, atau jaminan diterima kerja.